

# Feed Forward Neural Network with Back Propagation

## Application on MNIST Dataset

Eden BELOUADAH

9 décembre 2017

## 1 Introduction

Le domaine d'apprentissage profond est l'un des domaines les plus récents qui s'inspirent du domaine biomédical. Il trouve des applications dans plein de problématiques réelles parmi lesquelles la classification d'image.

Le but de ce travail pratique est de mettre en œuvre un réseau de neurones Feed Forward avec la rétropropagation de l'erreur, et de l'appliquer sur la base de données MNIST.

La base de données MNIST est contruite de 50000 exemples d'images binaires numérisées. Chaque image contient un chiffre manuscrit et le but du réseau est d'associer l'image au bon chiffre correspondant parmi 10.

## 2 Apprentissage du réseau de neurones

Afin de faire cette tâche, il a fallu implémenter ces fonctions :

- Forward : Faire le calcul matriciel nécessaire pour propager les données sur le réseau de neurones à partir de la couche d'entrée jusqu'à la couche de sortie,
- Softmax : Prendre les activations de la couche de sortie et les transformer en une probabilité d'appartenance des exemples aux différentes classes,
- ComputeLoss : Calculer l'erreur et la précision du réseau de neurones en comparant les sorties du réseau avec les vraies classes des exemples,
- BackPropagation : Rétropropagation de l'erreur sur le réseau à partir de la couche de sortie jusqu'à la première couche cachée,
- UpdateParameters : Mettre à jour les paramètres du réseau de neurones (les poids  $W$  et les biais  $B$ )

La fonction d'activation utilisée pour les couches cachées est ReLU donnée par la formule suivante :

$$\text{ReLU}(x) = \max(x, 0)$$

Les deux fonctions *sigmoid* et *tanh* ont été utilisées mais n'ont pas donné les meilleurs résultats. En effet, nous remarquons que lorsque les dérivées sont très petites, les deux fonctions *sigmoid* et *tanh* ne deviennent plus efficaces et l'effet du gradient disparaît.

### 3 Architecture du réseau de neurones

L'architecture du réseau de neurones utilisée est la suivante :

- Nombre de couches cachées : 1,
- Nombre de neurones dans la couche cachée : 300,
- Fonction d'activation : ReLU,
- Erreur : Quadratique,
- Taille de Batch : 500.

Le pas d'apprentissage  $\eta$  est initialisé au début à 0.001 et changera de valeur dynamiquement selon la valeur d'erreur qu'on cherche à optimiser. Si l'erreur diminue, on augmente le pas d'apprentissage par 20%, et si elle augmente, on retourne aux valeurs précédentes de W et de B et on diminue le pas d'apprentissage par 20%.

### 4 Analyse des résultats

Avec moins de 50 itérations, le réseau de neurone est capable d'atteindre une précision de 86%. Les résultats sont les suivants :

Ensemble	Précision	Erreur
<b>Apprentissage</b>	84.26%	0.51
<b>Validation</b>	86.01%	0.47

Tableau 1. Précision et Erreur sur les ensembles d'apprentissage et de validation

Les résultats sont assez bons pour un réseau de neurones à architecture simple.

Les courbes d'apprentissages sont les suivantes :




Figure 1. Précision et erreur sur les ensembles d'apprentissage et de validation

Nous remarquons que l'erreur sur les ensembles d'apprentissage et de validation diminue efficacement au fil des itérations, puis commence à se stabiliser à la fin lorsque on se trouve dans un optimum local.

Nous remarquons que même sans utiliser la régularisation, le modèle ne souffre pas de surapprentissage, vu que la courbe d'erreur sur l'ensemble de validation ne diverge pas de celle de l'ensemble d'apprentissage.

Quant à la précision, nous remarquons qu'elle est en train d'augmenter pour les deux ensembles, jusqu'à ce qu'elle se stabilise aux dernières itérations.

## 5 Conclusion

Ce travail pratique était une occasion pour voir de plus proche le fonctionnement des réseaux de neurones. Ces derniers peuvent changer d'architecture en variant le type du problème, sa difficulté, ses particularités...

La base de données MNIST représente une tâche de classification simple qui peut être résolue avec un réseau de neurone simple, même sans couches cachées, comme nous l'avons vu dans le travail pratique précédent. En effet, il était possible d'atteindre une précision de 87% facilement et en un peu de temps.

Les architectures complexes sont plus adaptées aux problèmes complexes qui nécessitent vraiment un réseau profond, c'est la raison pour laquelle on s'est contenté d'une seule couche cachée dans ce travail.